Exploratory Data Analysis pada Data Keamanan

Kecerdasan Buatan untuk Keamanan

Dosen: Zuliar Efendi, M.Kom.



Fokus: memahami data sebelum membuat model deteksi, klasifikasi, atau analisis keamanan.

Target Pembelajaran Minggu 3

Capaian Praktikum

- Menjelaskan tujuan EDA dalam proyek AI for Security.
- Membaca struktur dataset keamanan dan data dictionary.
- Mengecek kualitas data: missing value, duplikasi, outlier, dan distribusi label.
- Menyusun temuan awal sebagai dasar preprocessing dan modeling.



Output utama: Notebook EDA dan Data Profiling Report untuk dataset proyek kelompok.

Posisi Minggu 3 dalam Alur PjBL

Project-Based Learning

M1 Problem Statement → M2 Data Understanding → M3 Preprocessing → M4 Baseline Model → M5 Improvement

Minggu 3 berada pada fase Data Understanding. Mahasiswa belum fokus mengejar akurasi, tetapi memahami karakter data dan risiko kesalahan analisis.

- Hasil EDA menentukan keputusan preprocessing.
- Temuan EDA memengaruhi pilihan fitur dan model.
- Interpretasi EDA menjadi dasar evaluasi keamanan.

Apa Itu Exploratory Data Analysis?

Konsep Inti

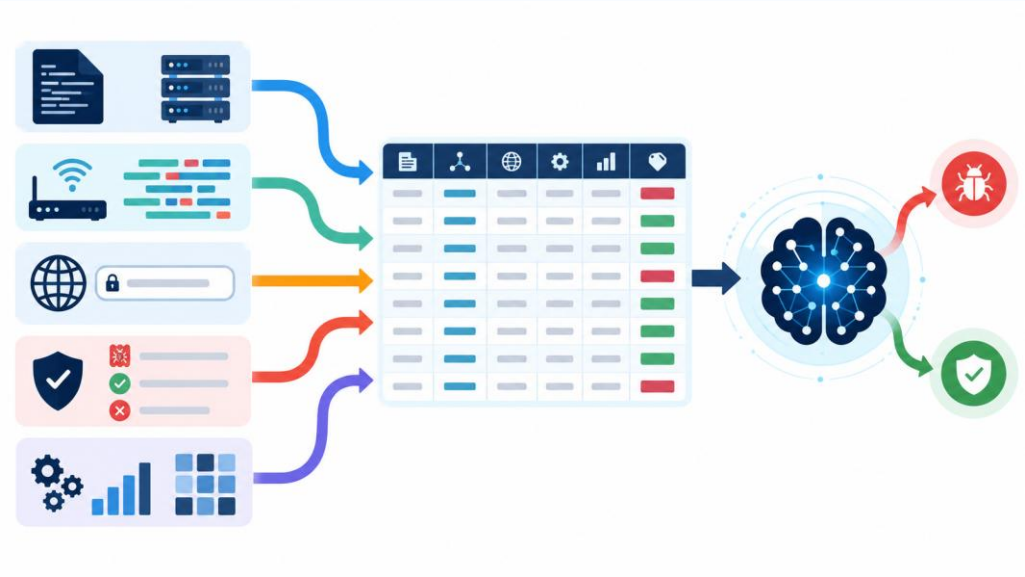
EDA adalah proses memahami bentuk, kualitas, pola, dan anomali data sebelum model machine learning dibangun.

- Mengubah dataset mentah menjadi informasi yang dapat dijelaskan.
- Membantu memilih fitur relevan untuk kasus keamanan.
- Mengurangi risiko data leakage, bias, dan salah interpretasi.
- Menjadi dasar keputusan preprocessing dan evaluasi.



Struktur Dataset Keamanan

Security Data



Sumber umum: log, network flow, URL, alert IDS, endpoint event, dan application log.

- Unit observasi: satu flow, satu URL, atau satu event.
- Fitur: duration, protocol, bytes, flags, request pattern.
- Label: benign, attack, phishing, suspicious, atau normal.
- Target: klasifikasi, deteksi anomali, atau prioritisasi alert.

Data Dictionary: Kamus Sebelum Analisis

Praktik Wajib

Kolom yang tidak dipahami akan menghasilkan model yang sulit dijelaskan. Data dictionary membantu mahasiswa menghubungkan fitur dengan konteks keamanan.

CONTOH ISI DATA DICTIONARY

- Nama fitur: duration
- Tipe data: numerik
- Makna: lama koneksi jaringan
- Status: dipakai sebagai fitur
- Catatan: perlu cek outlier

TUGAS KELOMPOK

- Pilih minimal 5 fitur utama.
- Jelaskan makna keamanan setiap fitur.
- Tandai fitur yang menjadi label.
- Catat fitur yang berisiko data leakage.

Cek Kualitas Data Keamanan

Data Profiling

- Missing values: data kosong pada kolom penting.
- Duplikasi: baris berulang yang mengganggu evaluasi.
- Outlier ekstrem: nilai tidak wajar pada durasi, bytes, atau packet count.
- Distribusi label: proporsi normal dan serangan.
- Tipe data salah: angka terbaca sebagai teks atau waktu tidak terformat.
- Data leakage: fitur yang membocorkan label secara tidak sah. Misal: password dan username



Security data sering besar, tidak seimbang, dan mengandung noise. Kualitas data menentukan kualitas deteksi.

Distribusi Label dan Class Imbalance

Kelas Normal vs Serangan

Pada kasus keamanan, data normal sering jauh lebih banyak daripada data serangan. Accuracy saja dapat menyesatkan.

Contoh distribusi label:
Normal: 8.600
DoS: 940
Scan: 620
Brute Force: 310
Botnet: 120

- Periksa jumlah data tiap label.
- Catat kelas minoritas dan mayoritas.
- Hubungkan imbalance dengan false negative.
- Rencanakan metrik selain accuracy.

Missing Value, Duplikasi, dan Outlier

Kualitas Data

MISSING VALUE

- Dampak: model tidak stabil atau gagal dilatih.
- Keputusan: drop, imputasi, atau investigasi.

DUPLIKASI

- Dampak: evaluasi tampak terlalu baik.
- Keputusan: hapus data duplikat.

OUTLIER

- Dampak: skala fitur dan batas keputusan bergeser.
- Keputusan: analisis, transformasi, atau clipping.

Semua keputusan pembersihan data harus dicatat pada notebook agar eksperimen dapat direplikasi.

Visualisasi untuk Menemukan Pola Awal

EDA Visual



- Histogram: melihat distribusi fitur numerik.
- Bar chart: melihat jumlah label atau kategori.
- Scatter plot: melihat pemisahan antar kelas.
- Correlation heatmap: melihat hubungan antar fitur.
- Line chart: melihat pola waktu pada log.

Setiap visual wajib diikuti interpretasi, bukan hanya gambar.

Contoh Kerangka Notebook EDA

Praktikum Python

```
import pandas as pd

df = pd.read_csv("security_dataset.csv")
print(df.shape)
print(df.info())
print(df.isna().sum())
print(df.duplicated().sum())
print(df["label"].value_counts())
print(df.describe())
```

- Gunakan nama file dan kolom sesuai dataset kelompok.
- Simpan output penting sebagai bukti analisis.
- Tambahkan komentar interpretatif pada setiap blok kode.
- Pisahkan section EDA, preprocessing, dan modeling.

Dari Temuan EDA ke Keputusan Modeling

Reasoning

Temuan EDA → Keputusan berikutnya

- Banyak missing value → imputasi atau buang kolom.
- Label tidak seimbang → pakai recall, F1-score, atau class weighting.
- Fitur numerik terlalu besar → scaling atau transformasi.
- Fitur kategori → encoding yang sesuai.
- Ada data leakage → hapus fitur yang membocorkan label.

Model yang baik harus dapat dijelaskan dari kualitas data dan konteks keamanan.

Praktikum PjBL Minggu 3

Aktivitas Kelompok

1. Buka dataset proyek dan pahami struktur kolom.
2. Buat data dictionary minimal 5 fitur.
3. Lakukan profiling: shape, tipe data, missing, duplikasi, statistik, label.
4. Buat minimal 2 visualisasi yang relevan.
5. Tuliskan 5 temuan EDA dan dampaknya pada preprocessing.



Diskusi kelas: setiap kelompok menyampaikan satu temuan EDA yang paling berpengaruh terhadap rencana model.

Tugas Minggu 3

Deliverable

Project Milestone 2: Data Understanding dan EDA

- Notebook EDA berisi import data, data profiling, visualisasi, dan interpretasi.
- Data dictionary minimal 5 fitur utama.
- Minimal 2 temuan EDA dengan bukti grafik atau statistik.
- Rencana preprocessing awal untuk missing, outlier, encoding, dan scaling..

Format: PDF singkat + notebook .ipynb atau link Google Colab

Rubrik Penilaian Minggu 3

Milestone EDA

Bobot penilaian:

- Kejelasan dataset dan problem security: 15%
- Data dictionary dan pemahaman fitur: 20%
- Kelengkapan data profiling: 20%
- Kualitas visualisasi dan interpretasi: 25%
- Rencana preprocessing dan repository: 20%

Checklist sebelum dikumpulkan:

- Notebook dapat dijalankan ulang.
- Grafik punya interpretasi jelas.
- Keputusan preprocessing punya alasan.
- Dataset dan fitur mengikuti etika penggunaan data.
- Kontribusi anggota terlihat di repository.

Keluaran Akhir Pertemuan 3

Ringkasan



- Kelompok memahami dataset proyek secara faktual.
- Kelompok memiliki data dictionary awal.
- Kelompok mengetahui masalah kualitas data.
- Kelompok memiliki visualisasi dan temuan EDA.
- Kelompok siap masuk ke preprocessing minggu 4.

Refleksi: fitur mana yang paling relevan untuk keputusan keamanan, dan fitur mana yang berpotensi menyesatkan model?