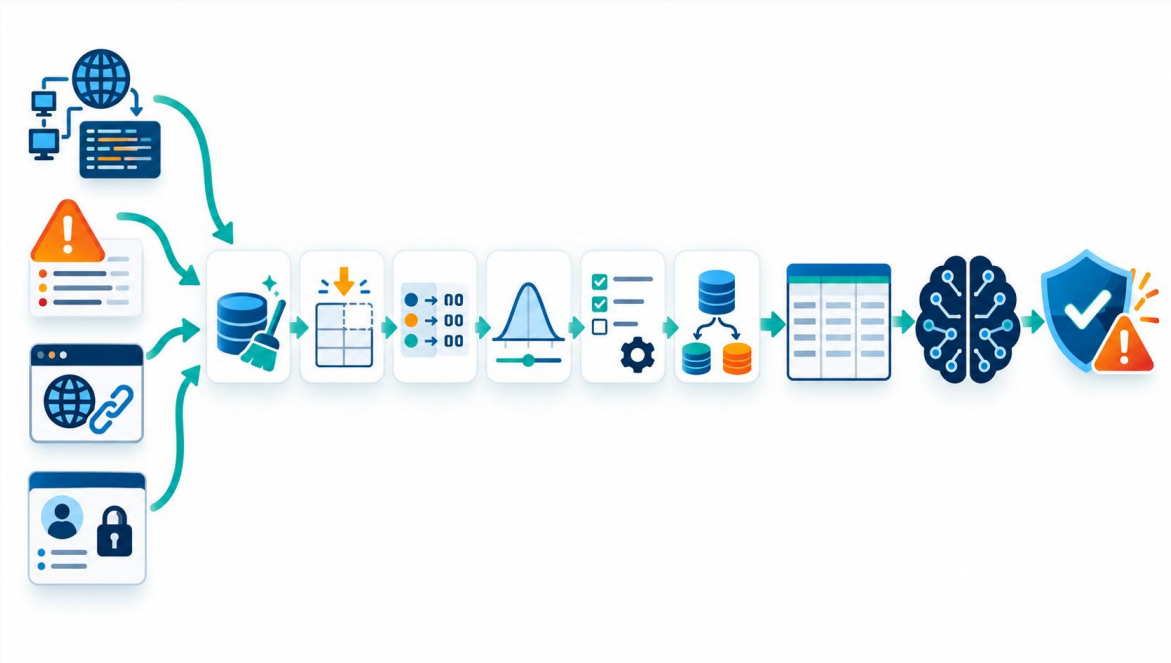
Pertemuan 4

Data Preprocessing untuk AI Security

Mempersiapkan data keamanan agar layak untuk pemodelan machine learning.

Project-Based Learning

Praktik Python



Dosen: Zuliar Efendi, M.Kom.

Koneksi dengan Pertemuan Sebelumnya

Minggu 3 sudah mengenalkan EDA dan pemahaman dataset keamanan.

Minggu 2

Problem formulation, pemilihan kasus keamanan, target model, dan sumber dataset.

Minggu 3

Exploratory Data Analysis: struktur data, distribusi label, missing values, outlier, dan pola awal.

Minggu 4

Data preprocessing: membersihkan, mengubah, membagi, dan menyiapkan data untuk training model.

Pertanyaan

“Jika dataset masih kotor, tidak seimbang, dan bocor antara training–testing, apakah model dengan akurasi tinggi dapat dipercaya?”

Capaian Pertemuan 4

Mahasiswa menghubungkan kualitas data dengan validitas model keamanan.

1

Menjelaskan tujuan preprocessing pada dataset keamanan.

2

Membersihkan missing value, duplikasi, dan data tidak konsisten.

3

Melakukan encoding, scaling, dan feature selection dasar.

4

Membagi data menjadi train-test tanpa data leakage.

5

Menyusun preprocessing pipeline awal untuk proyek kelompok.



Masalah Umum pada Dataset Keamanan

Preprocessing dimulai dari memahami risiko kualitas data.

Missing value

Log tidak lengkap, field kosong, capture gagal.

Duplikasi

Event sama tercatat berulang atau flow ganda.

Format tidak konsisten

Timestamp, IP, port, label, dan kategori tidak seragam.

Outlier

Nilai ekstrem dapat berarti serangan atau kesalahan data.

Class imbalance

Data normal jauh lebih banyak dari data serangan.

Data leakage

Informasi testing tidak sengaja masuk ke training.

Alur Preprocessing untuk AI Security

Ubah data mentah menjadi tabel fitur yang siap digunakan model.



1. Data mentah
2. Cleaning
3. Encoding
4. Scaling
5. Split
6. Dataset siap model

Langkah 1: Cleaning Data

Tujuan: mengurangi noise tanpa menghapus sinyal serangan yang penting.

Missing value

Cek kolom kosong. Isi dengan nilai logis, median, modus, atau tandai sebagai kategori unknown.

Duplikasi

Hapus baris duplikat jika event benar-benar sama. Jangan hapus event serangan berulang yang valid.

Inconsistent format

Samakan tipe data: waktu, IP, port, protocol, label, dan angka numerik.

```
# contoh awal
df.info()
df.isna().sum()
df.duplicated().sum()

# hapus duplikasi tepat
df = df.drop_duplicates()
```

Prinsip untuk data keamanan

- Jangan menghapus outlier sebelum memahami konteksnya.
- Serangan sering muncul sebagai pola langka.
- Catat keputusan cleaning di experiment log.

Missing Value: Pilih Strategi dengan Alasan

Tidak semua kolom kosong harus diperlakukan sama.

Kolom numerik

Median sering lebih aman saat distribusi miring.

Kolom kategori

Gunakan modus atau nilai “unknown”.

Kolom label

Jangan menebak label serangan. Hapus atau validasi manual.

Kolom kritis

Jika terlalu banyak kosong, pertimbangkan drop column.

```
num_cols = ['duration','bytes','packets']
cat_cols = ['protocol','service']

from sklearn.impute import SimpleImputer

num_imputer = SimpleImputer(strategy='median')
cat_imputer = SimpleImputer(strategy='most_frequent')
```

Langkah 2: Encoding dan Scaling

Model ML membutuhkan angka. Data kategori perlu diubah dengan hati-hati.

Encoding

- One-Hot Encoding untuk protocol, service, flag, atau kategori nominal.
- Label Encoding hanya aman jika urutan kategorinya bermakna.

Scaling

- StandardScaler untuk model yang sensitif terhadap skala.
- MinMaxScaler berguna untuk rentang 0–1.

```
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer

preprocess = ColumnTransformer([
    ('num', StandardScaler(), num_cols),
    ('cat', OneHotEncoder(handle_unknown='ignore'), cat_cols)
])
```

Langkah 3: Feature Selection

Tujuan: memilih fitur yang relevan, stabil, dan dapat dijelaskan.

Hapus fitur tidak informatif

Kolom ID, timestamp mentah, atau kolom konstan sering tidak membantu model.

Cek korelasi ekstrem

Fitur yang terlalu mirip dapat memperberat model dan mengaburkan interpretasi.

Waspadai leakage feature

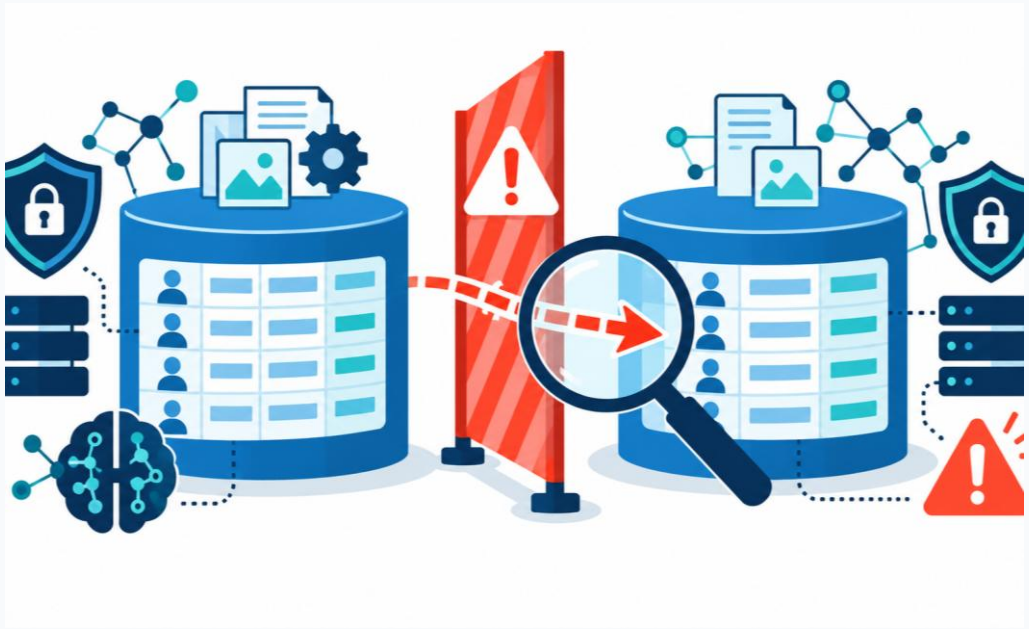
Contoh: kolom “attack_category” dipakai untuk memprediksi “is_attack”.

Pertanyaan analitis

- Apakah fitur tersedia saat model berjalan di dunia nyata?
- Apakah fitur tersebut hasil keputusan manusia setelah kejadian?
- Apakah fitur membuat model “terlalu mudah” karena membawa jawaban?

Train–Test Split dan Data Leakage

Evaluasi model hanya sah jika data testing benar-benar belum pernah dilihat model.



Aturan utama

Lakukan split sebelum fit scaler, imputer, encoder, atau feature selector. Semua transformasi harus belajar dari training set.

Gunakan stratify

Untuk classification, stratify membantu menjaga proporsi normal dan attack pada train dan test.

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

Bangun Pipeline agar Reproducible

Pipeline mencegah langkah preprocessing dilakukan manual dan tidak konsisten.

```
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestClassifier

model = Pipeline([
    ('preprocess', preprocess),
    ('clf', RandomForestClassifier(random_state=42))
])

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Manfaat pipeline

- Urutan kerja lebih jelas.
- Eksperimen mudah diulang.
- Risiko data leakage turun.
- Tim lebih mudah kolaborasi di proyek.
- Cocok untuk baseline modeling minggu berikutnya.

Praktik Python: Notebook Minggu 4

Mahasiswa menyiapkan dataset proyek kelompok.



Struktur notebook

- Import library dan dataset
- Cek struktur, label, missing value
- Pisahkan fitur dan target
- Train-test split
- Buat preprocessing pipeline
- Simpan data siap olah

Output praktik

Notebook .ipynb, preprocessing summary, dan catatan keputusan data cleaning.



Ringkasan

- Preprocessing menentukan kualitas evaluasi model.
- Cleaning harus punya alasan dan catatan.
- Encoding dan scaling harus masuk pipeline.
- Train-test split wajib mencegah leakage.
- Minggu 5 masuk ke baseline modeling.

Tugas: kumpulkan notebook preprocessing dan preprocessing summary.