PEMILIHAN ALGORITMA
KECERDASAN BUATAN UNTUK KEAMANAN
Deteksi Intrusi Jaringan Berbasis Machine Learning
menggunakan Dataset NSL-KDD

Dosen Pengampu:

ZULIAR EFENDI, M.Kom

Disusun Oleh:

HANDAL KARIS ARBI (NIM. 6404240007)

MARKUS EDISON SILALAHI (NIM. 6404240005)

JURUSAN TEKNIK INFORMATIKA

PROGRAM STUDI KEAMANAN SISTEM INFORMASI

POLITEKNIK NEGERI BENGKALIS

2026

1. Algoritma yang dipilih dan Alasan

Algoritma yang dipilh adalah Random Forest, karena data proyek berbentuk tabel dengan campuran fitur numerik dan kategorikal, target yang diprediksi adalah label biner normal atau attack, dan model perlu stabil serta mampu menangkap pola trafik jaringan yang tidak linear.

Alasan lainnya:

1. **Cocok untuk data tabular dengan banyak fitur**

Dataset berbentuk tabel dengan 41 fitur campuran numerik dan kategorikal, dan beberapa penelitian pada NSL-KDD menempatkan Random Forest di antara algoritma dengan performa terbaik (Abrar dkk., 2020; Cholakoska dkk., 2021).

2. Stabil terhadap fitur yang miring dan outlier

Hasil EDA menunjukkan fitur duration, src_bytes, dan dst_bytes sangat miring dengan outlier ekstrem.Model berbasis pohon relatif tahan terhadap kondisi ini, dan gabungan banyak pohon lebih stabil daripada satu DecisionTree. Breiman (2001) juga menunjukkan bahwa Random Forest lebih tahan terhadap noise dibandingkan Adaboost.

3. Sesuai dengan ukuran data

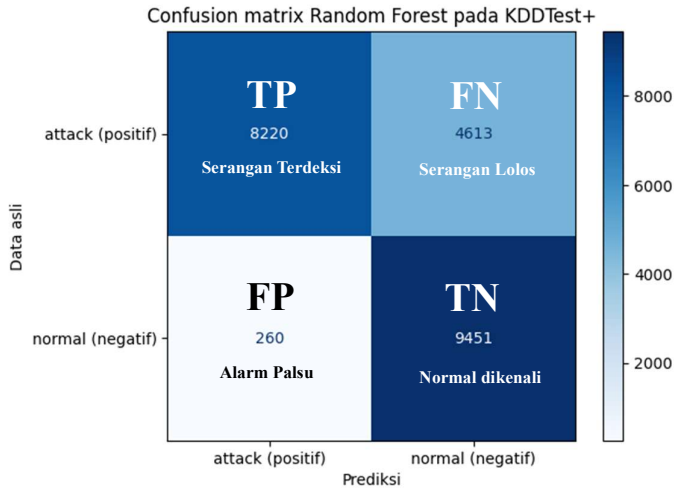
Dengan 125.973 baris data latih, random forest berjalan mudah (model selesai dilatih dalam 16.1 detik di Google Colab), sedangkan KNN dan SVM berat pada data sebesar ini dan logistic regression kemungkinan terlalu sederhana untuk pola serangan yang beragam.

4. Hasilnya dapat dijelaskan

Random forest menyediakan feature importance (Breiman, 2001), sehingga analisis SOC dapat melihat fitur mana yang paling menentukan keputusan model (Bagian 4).

2. Hasil Pengujian pada Data Test

Model diuji pada KDDTest+ yang berisi 22.544 koneksi (12.833 attack) dan 9.711 normal).



Gambar 1 Confusion Matrix Random Forest pada KDDTest+ (kelas positif: attack)

Tabel 1. Metrik hasil pengujian

Metrik	Nilai	Arti
Accuracy	78,38%	17.671 dari 22.544 prediksi benar
Precision (attack)	96,93%	Dari semua prediksi attack 96,93% yang memang serangan
Recall	64,05%	Dari semua serangan asli, hanya 64,05% yang tertangkap
F1-Score	77,14%	Keseimbangan antara precision dan recall
Akurasi validasi internal (tahap M4)	99,9%	Split 80/20 dari KDDTrain+, hanya sebagai pembanding

Akurasi pada KDDTest+ (78,38%) jauh lebih rendah daripada akurasi validasi internal pada tahap M4 (99,9%). Perbedaan ini wajar karena KDDTest+ memuat 17 jenis serangan yang tidak ada pada data latih, dan sejalan dengan penelitian lain yang melaporkan akurasi biner terbaik 86% pada KDDTest+ (Pardeshi & Patil, 2024). Hasil berasal dari satu kali pelatihan dengan random_state = 42.

Lima fitur yang paling berpengaruh menurut feature importance adalah src_bytes (0,1097), src_bytes_log (0,1001), flag (0,0933), dst_bytes (0,0776), dan dst_bytes_log (0,0749). Jumlah byte yang dikirim dan status koneksi (flag) paling

menentukan keputusan model. Nilai importance src_bytes dan dst_bytes terbagi dengan versi log1p dari fitur yang sama karena pohon keputusan tidak terpengaruh transformasi monoton, sehingga kedua versi membawa informasi yang sama.

3. Penjelasan TP, TN, FP, dan FN

Tabel 2. Makna TP, TN, FP, dan FN pada proyek deteksi intrusi

Istilah	Arti dalam proyek	Jumlah	Dampak bagi analis SOC
TP	Koneksi serangan yang diprediksi attack. Model berhasil menemukan kasus penting	8.220	Serangan terdeteksi dan muncul sebagai alert untuk dianalisis
TN	Koneksi normal yang diprediksi normal. Model mengenali aktivitas biasa dengan benar	9.451	97,32% koneksi normal dikenali dengan benar, jadi tidak ada alert yang tidak perlu
FP	Koneksi normal yang diprediksi attack. Ini menghasilkan alarm palsu	260	Menambah pekerjaan pengecekan analis SOC, tetapi jumlahnya kecil (2,68% dari koneksi normal)
FN	Koneksi serangan yang diprediksi normal. Serangan penting lolos dari deteksi	4.613	Risiko terbesar: 35,95% serangan lolos tanpa alert

Kesalahan model tidak seimbang: alarm palsu sedikit (FP = 260), tetapi serangan yang lolos sangat banyak (FN = 4.613). Tabel 3 menunjukkan bahwa FN terkonsentrasi pada serangan R2L dan U2R, sedangkan DoS dan Probe relatif baik (recall di atas 81%).

Tabel 3. Recall per kategori serangan pada KDDTest+

Kategori Serangan	Jumlah di KDDTest+	Terdeteksi (TP)	Lolos (FN)	Recall
DoS	7.460	6.100	1.360	81,77%
Probe	2.421	1.962	459	81,04%
R2L	2.885	151	2.734	5,23%
U2R	67	7	60	10,45%
Total	**12.833**	**8.220**	**4.613**	**64,05%**

Serangan yang jenisnya ada di data latih terdeteksi dengan recall 76,70% (9.083 koneksi, 20 jenis), sedangkan 17 jenis serangan yang hanya muncul di KDDTest+ hanya terdeteksi 33,41% (3.750 koneksi).Sebanyak 54,13% dari seluruh FN berasal dari jenis serangan baru tersebut.

Lima jenis serangan yang paling banyak lolos adalah guess_passwd (1.231), warezmaster (812), processtable (660), mscan (455), dan apache2 (388). Dua yang pertama (guess_passwd dan warezmaster) termasuk R2L, kelas dengan data latih sangat sedikit (995 baris, dibanding 45.927 baris DoS), sedangkan processtable, mscan, dan apache2 adalah jenis serangan baru yang tidak ada di data latih.

4. Kesimpulan dan Rencana Perbaikan

Model cukup baik pada bagian precision serangan (96,93%) dan pengenalan koneksi normal (97,32%), sehingga alarm palsu relatif sedikit (FP = 260). Namun, model masih memiliki masalah pada recall serangan yang hanya 64,05% (FN = 4.613), terutama pada serangan R2L (5,23%) dan U2R (10,45%) serta pada jenis serangan yang tidak ada di data latih (recall 33,41%). Karena serangan yang lolos adalah kesalahan paling berbahaya bagi analis SOC, model ini belum cukup baik dan perlu diperbaiki. Akurasi 78,38% saja tidak cukup untuk menilai model karena menyembunyikan besarnya FN.

Perbaikan selanjutnya:

1. Naikkan recall serangan.

Coba class_weight="balanced" dan turunkan ambang keputusan probabilitas (predict_proba), lalu periksa kenaikan FP sebagai konsekuensinya.

2. Perbaiki deteksi kelas minoritas dan serangan baru.

Lakukan seleksi fitur dan tuning hyperparameter dengan grid search, serta tangani ketidakseimbangan kelas pada R2L dan U2R. Untuk jenis serangan baru, pertimbangkan pendekatan yang lebih umum seperti deteksi anomali atau pembaruan data latih secara berkala.

3. Bandingkan dengan algoritma boosting.

Pada penelitian lain, Gradient Boosting memberi akurasi biner terbaik pada KDDTest+ (Pardeshi & Patil, 2024), sehingga layak dicoba sebagai pembanding setelah Random Forest diperbaiki.

DAFTAR PUSTAKA

Abrar, I., Ayub, Z., Masoodi, F., & Bamhdi, A. M. (2020). A Machine Learning Approach for Intrusion Detection System on NSL-KDD Dataset. *2020 International Conference on Smart Electronics and Communication (ICOSEC)*, 919–924. https://doi.org/10.1109/ICOSEC49089.2020.9215232

Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cholakoska, A., Shushlevska, M., Todorov, Z., & Efnusheva, D. (2021). *Analysis of Machine Learning Classification Techniques for Anomaly Detection with NSL-KDD Data Set* (pp. 258–267). https://doi.org/10.1007/978-3-030-90321-3_21

G. Pardeshi, N., & V. Patil, D. (2024). Binary and Multiclass Classification Intrusion Detection System using Benchmark NSL-KDD and Machine Learning Models. *2024 International Conference on Data Science and Network Security (ICDSNS)*, 1–7. https://doi.org/10.1109/ICDSNS62112.2024.10691256