PERBANDINGAN ALGORITMA LAIN
KECERDASAN BUATAN UNTUK KEAMANAN
Deteksi Intrusi Jaringan Berbasis Machine Learning menggunakan Dataset NSL-KDD

Dosen Pengampu:

ZULIAR EFENDI, M.Kom

Disusun Oleh:

HANDAL KARIS ARBI (NIM. 6404240007)

MARKUS EDISON SILALAHI (NIM. 6404240005)

JURUSAN TEKNIK INFORMATIKA

PROGRAM STUDI KEAMANAN SISTEM INFORMASI

POLITEKNIK NEGERI BENGKALIS

2026

Algoritma yang dibandingkan dan Alasan

Dua algoritma yang dibandingkan adalah Gradient Boosting (GB) dan Logistic Regression (LR). GB adalah model berbasis pohon keputusan yang trainning secara berurutan, dan setiap pohon baru memperbaiki kesalahan pohon sebelumnya. Model ini dapat menangkap pola non linear dan interaksi antar fitur. LR adalah model linear yang menghitung pola non linear dan interaksi antar fitur. LR adalah model linear yang menghitung peluang sebuah koneksi adalah serangan dari kombinasi linear fitur. Model ini sederhana, cepat dilatih, dan koefisiennya mudah dibaca.

Alasan memabndingkan keduanya:

1. Mewakili dua pendekatan berbeda.

LR menjadi baseline linear dan GB menjadi model non linear, sehingga terlihat apakah pola serangan NSL-KDD cukup dipisahkan secara linear.

2. Ada dugaan yang diuji.

Data trafik memuat fitur yang sangat miring (duration, src_bytes, dst_bytes), fitur kategorikal dengan banyak nilai (service), dan perilaku serangan yang beragam, sehingga model non linear diduga lebih sesuai. GB juga memberi akurasi biner terbaik pada KDDTest+ pada penelitian lain (Pardeshi & Patil, 2024).

3. Data dan preprocessing sama.

Kedua model memakai 125 fitur hasil tahap M4, sehingga perbedaan hasil berasal dari algoritma, bukan dari data.

2. Skenario Uji dan Tolak Ukur

- Data latih KDDTrain+ (125.973 baris) dan data uji KDDTest+ (22.544 baris, 12.833 attack dan 9.711 normal), kelas positif: attack.
- Preprocessing sama dengan tahap M4: OneHotEncoder, StandardScaler, dan tiga fitur log1p, menghasilkan 125 fitur.
- Gradient Boosting: n_estimators 100, learning_rate 0,1, max_depth 3 (nilai bawaan), random_state 42.
- Logistic Regression: max_iter 1000, random_state 42, regularisasi L2 dengan C 1,0 (nilai bawaan).
- Tolak ukur utama: Recall dan F1-Score. Loss dihitung sebagai jumlah kesalahan prediksi (FN + FP). Loss yang tinggi, terutama FN, berarti ada celah keamanan karena serangan lolos tanpa alert.
- Hasil utama memakai ambang keputusan standar 0,5. Pengaruh ambang lain dibahas pada Bagian 4.5.

3. Hasil Perbandingan pada KDDTest+

Tabel 1. Perbandingan metrik Gradient Boosting dan Logistic Regression

Metrik	Gradient Boosting	Logistic Regression	Selisih GB
Accuracy	80,66%	73,61%	+7,05 poin
Precision (attack)	97,17%	91,08%	+6,09 poin
Recall (utama)	**68,00%**	**59,46%**	**+8,54 poin**
F1-Score (utama)	**80,01%**	**71,95%**	**+8,06 poin**
FN (serangan lolos)	4.107	5.203	1.096 lebih sedikit
FP (alarm palsu)	254	747	493 lebih sedikit
Loss (FN + FP)	4.361	5.950	1.589 lebih sedikit
Waktu latih	42,6 detik	2,5 detik	LR lebih cepat

Accuracy GB 80,66% dan LR 73,61%. Accuracy menyembunyikan besarnya FN, sehingga bukan tolak ukur utama.

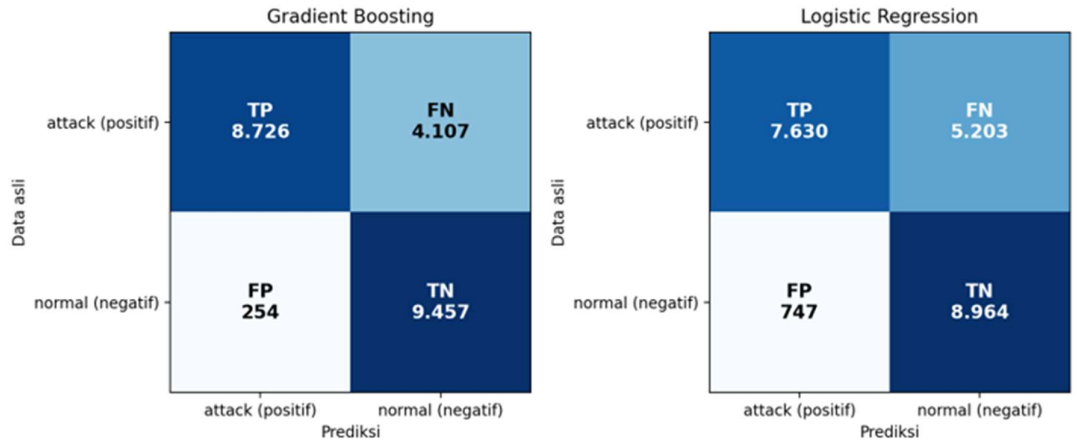
Precision GB 97,17% dan LR 91,08%. Dari setiap 100 alert, sekitar 3 salah pada GB dan sekitar 9 salah pada LR, sehingga beban analis SOC lebih besar pada LR.

Recall GB 68,00% dan LR 59,46%. Serangan yang lolos 32,00% pada GB dan 40,54% pada LR, selisih 1.096 serangan.

F1-Score GB 80,01% dan LR 71,95%, selisih 8,06 poin.

Loss LR 5.950 dan GB 4.361. Selisih 1.589 terdiri atas 1.096 FN dan 493 FP, jadi LR lebih buruk di kedua sisi, dan sisi FN adalah celah keamanan yang lebih besar.

Waktu latih LR jauh lebih cepat karena hanya menghitung satu set koefisien, sedangkan GB melatih 100 pohon secara berurutan. Nilai waktu bergantung pada mesin yang dipakai.



Gambar 1 Confusion Matrix Gradient Boosting dan Logistic Regression pada KDDTest+ (kelas positif: attack)

Analisis dari Berbagai Sisi

Tabel 2. Makna TP, TN, FP, dan FN pada kedua model

Istilah	**Arti dalam proyek**	**Gradient Boosting**	**Logistic Regression**
TP	Serangan diprediksi attack (terdeteksi)	8.726	7.630
TN	Koneksi normal diprediksi normal	9.457	8.964
FP	Koneksi normal diprediksi attack (alarm palsu)	254	747
FN	**Serangan diprediksi normal (lolos)**	**4.107**	**5.203**

Koneksi normal dikenali 97,38% oleh GB dan 92,31% oleh LR (FP rate 2,62% dan 7,69%). Pada kedua model kesalahan tetap tidak seimbang, yaitu FN jauh lebih besar daripada FP, tetapi pada LR kedua kesalahan itu lebih besar.

Recall per kategori serangan

Tabel 3. Recall per kategori serangan pada KDDTest+

Kategori	Jumlah	Recall GB	Recall LR	FN GB	FN LR
DoS	7.460	84,13%	77,47%	1.184	1.681
Probe	2.421	83,23%	75,42%	406	595
R2L	2.885	14,77%	0,42%	2.459	2.873
U2R	67	13,43%	19,40%	58	54
Total	**12.833**	**68,00%**	**59,46%**	**4.107**	**5.203**

GB lebih baik pada DoS (84,13% dibanding 77,47%) dan Probe (83,23% dibanding 75,42%). Perbedaan terbesar ada pada R2L: LR hanya mendeteksi 12 dari 2.885 koneksi (0,42%), sedangkan GB 426 koneksi (14,77%). Satu-satunya kategori yang dimenangkan LR adalah U2R (13 dibanding 9 dari 67 koneksi), tetapi selisih 4 koneksi itu terlalu kecil untuk ditarik kesimpulan kuat.

Serangan yang dikenal dan serangan baru

Tabel 4. Recall serangan yang ada dan tidak ada pada data latih

Kelompok serangan	Jumlah	Recall GB	Recall LR
Dikenal (20 jenis, ada di data latih)	9.083	78,72%	71,23%
Baru (17 jenis, hanya di data uji)	3.750	42,03%	30,93%

Kedua model jauh lebih lemah pada serangan baru. GB unggul 7,49 poin pada serangan dikenal dan 11,10 poin pada serangan baru. Serangan baru menyumbang 52,93% dari FN GB (2.174 koneksi) dan 49,78% dari FN LR (2.590 koneksi). Porsi pada LR lebih kecil karena LR juga banyak meloloskan serangan yang dikenal.

Serangan yang paling banyak lolos

Lima serangan yang paling banyak lolos pada GB adalah guess_passwd (1.231), processtable (684), warezmaster (634), mscan (398), snmpguess (331). Pada LR: guess_passwd (1.229), warezmaster (943), processtable (685), mscan (536), apache2 (354). Serangan guess_passwd (1.231 koneksi) hampir seluruhnya lolos pada kedua model. LR meloloskan lebih banyak warezmaster (943 dibanding 634) dan mscan (536 dibanding 398), sedangkan snmpguess (331 koneksi) lolos seluruhnya pada GB.

Pengaruh ambang keputusan

Tabel 5. Hasil pada beberapa ambang keputusan (data uji KDDTest+)

Model	Ambang	Recall	F1	FN	FP	Loss
Gradient Boosting	0,5	68,00%	80,01%	4.107	254	4.361
Gradient Boosting	0,3	70,42%	81,57%	3.796	287	4.083
Gradient Boosting	0,1	80,01%	87,36%	2.565	406	2.971
Logistic Regression	0,5	59,46%	71,95%	5.203	747	5.950
Logistic Regression	0,3	62,67%	74,16%	4.791	813	5.604
Logistic Regression	0,1	68,93%	78,04%	3.987	990	4.977

Menurunkan ambang dari 0,5 ke 0,1 menaikkan recall GB dari 68,00% menjadi 80,01% (FN turun 1.542, FP naik 152), dan recall LR dari 59,46% menjadi 68,93% (FN turun 1.216, FP naik 243). Pada ambang 0,1 GB tetap unggul, dengan loss 2.971 dibanding 4.977. Recall LR pada ambang 0,1 (68,93%) baru menyamai GB pada ambang standar (68,00%), tetapi dengan 990 alarm palsu, hampir 4 kali lipat FP GB (254). Catatan: ambang ini dicoba langsung pada data uji sebagai eksplorasi. Untuk penerapan nyata, ambang sebaiknya dipilih pada data validasi.

Pola yang dipelajari model

Lima fitur terpenting GB adalah src_bytes (0,5354), src_bytes_log (0,1681), service (0,1311), dst_bytes (0,0466), dst_bytes_log (0,0284), dengan src_bytes sangat dominan. Lima koefisien LR terbesar (nilai mutlak) adalah service_IRC (−9,283), flag_S1 (−5,817), num_root (−5,704), num_compromised (5,584), flag_S0 (5,419); koefisien positif mendorong prediksi attack dan negatif mendorong normal. LR lebih mudah dijelaskan arah pengaruhnya, tetapi kemampuan memisahkan kelasnya lebih rendah: AUC LR 0,7792 dibanding GB 0,9446, dan log loss LR 1,5817 dibanding GB 0,6631 (lebih rendah lebih baik). Jadi keunggulan GB tidak hanya muncul pada ambang 0,5, tetapi pada seluruh rentang ambang.

Kesimpulan dan Rencana Perbaikan

Gradient Boosting lebih cocok daripada Logistic Regression untuk deteksi intrusi pada NSL-KDD. Berdasarkan tolak ukur utama, recall GB 68,00% dibanding 59,46% dan F1-Score 80,01% dibanding 71,95%. Loss GB juga lebih rendah (4.361 dibanding 5.950), sehingga celah

keamanan lebih kecil: 1.096 serangan lebih sedikit lolos dan 493 alarm palsu lebih sedikit. Hasil ini mendukung dugaan bahwa pola serangan NSL-KDD tidak cukup dipisahkan secara linear.

Tabel 6. Ringkasan Penilaian

Aspek	Lebih baik	Bukti
Recall (utama)	GB	68,00% dibanding 59,46%
F1-Score (utama)	GB	80,01% dibanding 71,95%
Loss atau celah keamanan	GB	4.361 dibanding 5.950; FN 4.107 dibanding 5.203
Alarm palsu (FP)	GB	254 dibanding 747
Serangan baru	GB	42,03% dibanding 30,93%
Kecepatan latih	LR	2,5 detik dibanding 42,6 detik
Kemudahan dijelaskan	LR	Koefisien langsung menunjukkan arah pengaruh fitur
U2R	LR	13 dibanding 9 dari 67 koneksi (sampel kecil)

Meski lebih baik, GB belum menutup celah keamanan. Sebanyak 4.107 serangan (32,00%) masih lolos tanpa alert, recall R2L hanya 14,77%, dan recall serangan baru 42,03%. LR tetap berguna sebagai baseline yang cepat dan mudah dijelaskan. Hasil berasal dari satu kali pelatihan dengan random_state 42 dan parameter bawaan.

Perbaikan selanjutnya:

1. Turunkan ambang keputusan GB dengan memilihnya pada data validasi, lalu periksa kenaikan FP yang ditimbulkan.
2. Lakukan tuning learning_rate, n_estimators, dan max_depth pada GB dengan grid search, memakai recall dan F1-Score sebagai skor.
3. Tangani ketidakseimbangan kelas R2L dan U2R, dan pertimbangkan deteksi anomali atau pembaruan data latih secara berkala untuk serangan baru.

DAFTAR PUSTAKA

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, *29*(5). https://doi.org/10.1214/aos/1013203451

G. Pardeshi, N., & V. Patil, D. (2024). Binary and Multiclass Classification Intrusion Detection System using Benchmark NSL-KDD and Machine Learning Models. *2024 International Conference on Data Science and Network Security (ICDSNS)*, 1–7. https://doi.org/10.1109/ICDSNS62112.2024.10691256

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. Wiley. https://doi.org/10.1002/9781118548387