DATA PREPROCESSING
KECERDASAN BUATAN UNTUK KEAMANAN



Dosen Pengampu:

ZULIAR EFENDI, M.Kom

Disusun Oleh:

HANDAL KARIS ARBI (NIM. 6404240007)

MARKUS EDISON SILALAHI (NIM. 6404240005)

JURUSAN TEKNIK INFORMATIKA

PROGRAM STUDI KEAMANAN SISTEM INFORMASI

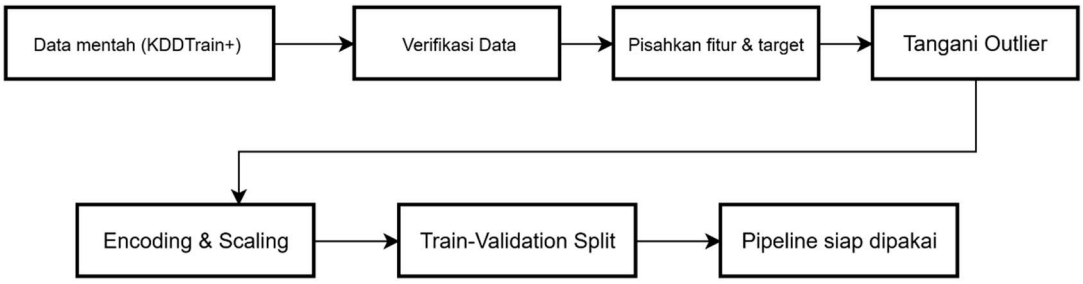
POLITEKNIK NEGERI BENGKALIS

2026

A. Latar Belakang & Problem Statement

Tahap ini melanjutkan hasil Exploratory Data Analysis (EDA) pada Minggu 3, yang menemukan bahwa dataset NSL-KDD sudah bersih dari missing value dan duplikasi, namun memiliki outlier ekstrem pada fitur volume traffic (duration, src_bytes, dst_bytes), ketimpangan kelas yang parah pada kategori serangan minoritas (R2L, U2R), serta kolom difficulty yang berisiko menyebabkan data leakage. Laporan ini merangkum keputusan pembersihan, transformasi, dan penyiapan data (data preprocessing) yang diambil berdasarkan temuan tersebut, sebelum data digunakan untuk baseline modeling di Minggu 5.

ALUR PREPROCESSING YANG DITERAPKAN



Ringkasan Keputusan Preprocessing

Aspek	Temuan / Alasan	Tindakan
Missing value & duplikasi	Dikonfirmasi ulang: 0 pada seluruh kolom	Tidak ada tindakan
Kolom difficulty	Metadata skor kesulitan dari pembuat dataset, bukan fitur jaringan asli	Dibuang dari fitur (X); tidak digunakan sama sekali
Kolom attack_category	Turunan langsung dari label class — berisiko data leakage jika jadi fitur	Dibuang dari fitur (X); dipakai sebagai target multiclass terpisah
Outlier duration, src_bytes, dst_bytes	Distribusi sangat right-skewed (temuan Minggu 3)	Ditambahkan versi log1p sebagai kolom baru; kolom asli tetap dipertahankan
Encoding kategorikal	protocol_type, service, flag bertipe kategorikal nominal	One-Hot Encoding lewat ColumnTransformer
Scaling numerik	Rentang nilai antar fitur numerik sangat berbeda	StandardScaler pada 38 fitur numerik (memakai

		versi log1p untuk 3 fitur yang skewed)
Pembagian data	Evaluasi harus bebas dari data leakage	Train-validation internal (80/20, stratified) dari KDDTrain+ saja; KDDTest+ disimpan utuh sebagai test set final
Pipeline	Proses perlu konsisten & reproducible	Disatukan dalam sklearn Pipeline (preprocess + model); fit hanya pada data training

C. Verifikasi Pipeline (Smoke Test)

Fitur	Hasil
Ukuran data training (internal)	100.779 x 44 kolom
Ukuran data validasi internal	25.195 baris x 44 kolom
Proporsi kelas (train & val)	Normal 53,5% / attack 46,5% - Identik, stratify berhasil
Model smoke test	RandomForestClassifier (default), sekedar mengetes pipeline
Accuracy pada validation set	99,9%

Accuracy 99,9% ini adalah hasil smoke test pada validation set yang diambil dari dalam KDDTrain+ sendiri, sehingga polanya masih sangat mirip dengan data training. Angka ini bukan evaluasi performa final — NSL-KDD secara sengaja merancang KDDTest+ agar berisi beberapa jenis serangan yang tidak muncul di KDDTrain+, untuk menguji apakah model benar-benar mempelajari pola serangan atau hanya menghafal data latih. Evaluasi yang jujur baru dapat diklaim setelah pipeline diuji pada KDDTest+ di Minggu 5, menggunakan metrik precision/recall/F1 per kelas (bukan hanya accuracy) mengingat ketimpangan kelas pada R2L dan U2R.

D. Kesimpulan

Seluruh tahapan preprocessing wajib cleaning, penanganan outlier, encoding, scaling, dan train-test split tanpa leakage telah diterapkan dan digabungkan dalam satu pipeline yang reproducible (preprocessing_pipeline_kelompok2.pkl). Keputusan-keputusan pada laporan ini menjadi dasar bagi kelompok untuk masuk ke tahap baseline modeling pada Minggu 5, dengan evaluasi akhir pada KDDTest+ menggunakan metrik yang mempertimbangkan ketimpangan kelas